

Isomorfismo Estrutural e os Limites Semânticos da Cognição Incorporada na Psicometria Generativa da Psicopatologia

Frederico Gonçalves Pedrosa

Resumo

A psicopatologia é mediada pela linguagem, sugerindo que a estrutura latente dos transtornos mentais está codificada na semântica utilizada para descrever os sintomas. Este trabalho objetivou investigar a convergência entre a covariação de respostas humanas e o espaço semântico de *Large Language Models* (LLMs), estabelecendo um protocolo de Psicometria Generativa. Utilizaram-se dados empíricos da DASS-21 ($N = 259$), PANAS ($N = 473$) e do conjunto clínico BDI-II/BAI ($N = 1.957$). Foram extraídos *embeddings* de três arquiteturas (Cohere, OpenAI e MPNet), processados por quatro algoritmos de *Machine Learning*. Na calibração interna da DASS-21, os modelos explicaram até 69% da variância (R^2). A *Pseudo Factor Analysis* (PFA) revelou isomorfismo estrutural quase perfeito, com correlação de $r = 0,98$ entre as cargas fatoriais humanas e sintéticas. O teste de generalização *zero-shot* revelou uma assimetria preditiva ditada pela Cognição Incorporada já que a IA transferiu o conhecimento com precisão para afetos abstratos e sintomas depressivos ($r = 0,46$), mas esbarrou em uma lacuna nos sintomas de ansiedade somática ($r = 0,23$). A análise de *Explainable AI* (XAI) identificou o Eixo Somático-Cognitivo e a Anedonia como os preditores clínicos primários. Os achados levantam evidências de validade para a IA como ferramenta para a calibração pré-empírica de instrumentos, demonstrando que a psicopatologia possui uma unidade ontológica na linguagem, limitada pela ausência de experiência fenomenológica visceral.

Palavras-Chave: Psicometria; Inteligência Artificial; Depressão; Ansiedade; Estresse.

1. Introdução

Embora sinais não-verbais e paraverbais ofereçam informações valiosas, o relato verbal, tal como a descrição subjetiva de sentimentos, pensamentos e sensações, permanece como o meio importante para a identificação de fenômenos psicopatológicos e o estabelecimento de diagnósticos clínicos (Kambeitz et al., 2025). Essa preponderância do texto implica que a estrutura subjacente aos transtornos mentais pode estar, de alguma forma, codificada na semântica utilizada para descrevê-los (Kjell et al., 2019; Rosenbusch et al., 2020). Sob essa ótica, os inventários psicométricos são recortes de um espaço semântico estruturado em que o sofrimento psíquico se manifesta.

A ideia de que as dimensões mais importantes da experiência humana estão registradas na linguagem remonta à Hipótese Lexical de Galton (1884). Contudo, o campo da psicometria tem testemunhado uma evolução sem precedentes com o

surgimento dos Modelos de Linguagem de Larga Escala (LLMs) (Kjell, Kjell, & Schwartz, 2024; Hommel & Arslan, 2025). Ao contrário das abordagens léxicas tradicionais, os LLMs transformam o texto em vetores multidimensionais (*embeddings*) que capturam não apenas palavras isoladas, mas relações contextuais e semânticas graduadas em espaços latentes de alta dimensionalidade (Garrido et al., 2024). Esses modelos funcionam como peritos semânticos que, ao serem expostos a bilhões de parâmetros de linguagem humana, podem refletir aspectos substanciais do conhecimento ontológico sobre o mundo e sobre a própria mente (Fang & Oberski, 2022).

Uma questão central nesse debate é a chamada Cognição Incorporada (*Embodied Cognition*), já que se questiona se uma inteligência artificial, desprovida de um corpo biológico, seria capaz de representar sintomas que emanam da experiência somática, como “tremores” ou “boca seca” (Bisk et al., 2020; Kjell et al., 2024). A teoria da cognição incorporada sugere que o significado linguístico está intrinsecamente ligado às simulações sensoriais e motoras (Barsalou, 2008; Wilson, 2002). Portanto, verificar se o espaço latente de um LLM consegue diferenciar sintomas de ordem fisiológica de sintomas de ordem puramente cognitiva representa um teste fundamental para a validade dessas ferramentas como simuladores da experiência humana.

Simultaneamente, a psicometria enfrenta uma crise de dimensionalidade, movendo-se de modelos categoriais e estanques (DSM) para estruturas hierárquicas e dimensionais, exemplificadas pela taxonomia HiTOP (*Hierarchical Taxonomy of Psychopathology*; Kotov et al., 2017). Essa transição enfatiza a existência de um Fator Geral¹ de psicopatologia (ou *p-factor*), sugerindo que a depressão, a ansiedade e o estresse compartilham um núcleo comum de sofrimento psíquico (*distress*). No contexto brasileiro, estudos com a *Depression, Anxiety and Stress Scale* (DASS-21) têm corroborado essa perspectiva, indicando que o modelo bifactor, que isola um fator geral de *distress* frente a fatores específicos, apresenta ajuste superior em amostras nacionais (Peixoto et al., 2021).

No que pese o potencial dos LLMs em replicar essas estruturas, a adoção dessas tecnologias na saúde mental é limitada pelo problema da “caixa-preta”. Modelos de aprendizado de máquina ultra-complexos podem apresentar alta acurácia preditiva, mas sua opacidade estatística gera desconfiança ética e clínica (Rudin, 2019; Ghassemi et al., 2021). Surge, então, a necessidade da *Explainable AI* (XAI), ou Inteligência Artificial

¹ Neste texto utilizaremos as expressões *p-factor*, Fator Geral e Eixo Transdiagnóstico como sinônimos.

Explicável. O uso de modelos interpretáveis, como as Árvores de Inferência Condicional (*ctree*), permite identificar se a IA utiliza critérios clínicos racionais ou meras associações estatísticas espúrias para organizar o conhecimento psicopatológico.

Dessa convergência entre a inteligência artificial e a psicometria dimensional, emerge o conceito de Psicometria Generativa. Propõe-se que a IA possa atuar como um uma representação estrutural idealizada de um construto (Espelho Platônico, Garrido et al., 2025; Kambeitz et al., 2025). Enquanto as respostas humanas são permeadas por ruídos conjunturais, tais como fadiga, viés de desejabilidade social ou erros de interpretação, a IA, ao processar apenas o conteúdo semântico purificado dos itens, poderia revelar a arquitetura lógica e sem ruído do instrumento (Garrido et al., 2025).

Desta forma, o presente estudo visa investigar a capacidade de três diferentes arquiteturas de LLM em mapear a estrutura de covariação humana da DASS-21 e testar sua validade de generalização trans-instrumento em dois níveis de complexidade: (1) na abstração afetiva da *Positive and Negative Affect Schedule* (PANAS; Watson et al., 1988) e (2) na sintomatologia clínica do Beck Depression Inventory-II (BDI-II; Beck et al., 1996) e Beck Anxiety Inventory (BAI; Beck et al., 1988). Por meio de um protocolo de Psicometria Generativa auditável, buscamos testar se a inteligência artificial é capaz de reconstruir o isomorfismo estrutural da psicopatologia, revelando as regras lógicas e a ancoragem somático-cognitiva que sustentam a organização do sofrimento psíquico na linguagem humana. As hipóteses testadas são:

- Hipótese 1 [H1] – Convergência Semântico-Empírica: A proximidade semântica no espaço latente dos LLMs correlaciona-se significativa e positivamente com a covariação de respostas humanas.
- Hipótese 2 [H2] – Generalização: Um modelo treinado na DASS-21 é capaz de generalizar o conhecimento para prever a estrutura de instrumentos inéditos tanto no nível de afetos abstratos (PANAS) quanto de sintomatologia clínica (BDI-II e BAI).
- Hipótese 3 [H3] – Isomorfismo Estrutural: modelos de IA são capazes de reconstruir a arquitetura fatorial teórica (Análise Fatorial Confirmatória) por meio de uma matriz sintética de correlações.
- Hipótese 4 [H4] – Especialização Sintática vs. Conceitual: Modelos globais superam modelos locais especializados na replicação interna e na generalização entre instrumentos de mensuração devido ao tamanho dos vetores.

- Hipótese 5 [H5] – Dominância Transdiagnóstica: A estrutura semântica da psicopatologia nos LLMs converge para um fator geral de sofrimento (*Distress*), apresentando maior consistência no modelo bifatorial, assim como nos dados humanos.
- Hipótese 6 [H6] – Interpretabilidade e Racionalidade Semântica: A relação entre o espaço latente dos LLMs e a covariação humana é governada por regras lógicas e dimensões identificáveis por modelos interpretáveis, permitindo o mapeamento de critérios clínicos subjacentes às decisões da IA.
- Hipótese 7 [H7] – Cognição Incorporada: A acurácia da Psicometria Generativa é moderada pela natureza fenomenológica do sintoma, apresentando maior precisão em sintomas cognitivo-afetivos do que em sintomas viscerais e fisiológicos.

2. Metodologia

Esta pesquisa, de natureza metodológica e quantitativa com dados secundários, visa investigar as relações entre a covariação de respostas humanas a instrumentos psicométricos e as representações matemáticas (*embeddings*) geradas por Inteligência Artificial. O estudo está estruturado em duas etapas: (1) o estabelecimento de uma arquitetura empírica de referência (*ground truth*) baseada em dados humanos e (2) o levantamento de evidências de validade de um modelo de Psicometria Generativa via aprendizado de máquina e explicabilidade. Toda a programação e análise estatística foram realizadas em ambiente R (v.4.5.0; R Core Team, 2025).

2.1. Instrumentos e Participantes

Os dados de resposta à *Depression, Anxiety and Stress Scale* (DASS-21; Lovibond & Lovibond, 1995; Vignola & Tucci, 2014) foram obtidos por meio do projeto “Efeitos agudos e crônicos da musicoterapia receptiva com o gongo terapêutico em indivíduos com sintomas de ansiedade” (CAAE 77536623.2.0000.5150). Participaram deste estudo 259 pessoas, com idade média de 27,41 anos (DP = 6,69) e predomínio de 79,15% de mulheres.

Já os dados referentes à *Positive and Negative Affect Schedule* (PANAS; Watson et al, 1988; Nunes et al., 2019) provêm do projeto “Medindo a influência das relações com a música no desenvolvimento humano: uma abordagem psicométrica” (CAAE

74309523.6.0000.5149). Esta amostra foi composta por 473 pessoas, com idade média de 36,94 anos ($DP = 13,18$) e predominância de mulheres (62,81%).

Uma amostra Clínica Global (Anunciação, 2022) avaliada pelos instrumentos *Beck Depression Inventory* (BDI-II; Beck et al., 1996; Cunha, 2001) e *Beck Anxiety Inventory* (BAI; Beck et al., 1988; Cunha, 2001), composta por 1.957 estudantes universitários do Brasil, Portugal e Espanha ($M_{idade} = 21,46$; $DP = 3,82$; 62,03% mulheres), foi utilizada para garantir elevado poder estatístico e estabilidade psicométrica para o teste definitivo de isomorfismo estrutural e generalização *zero-shot*.

2.2. Extração Semântica e Arquiteturas de LLM

Para representar o conteúdo dos itens de forma vetorial, utilizamos três arquiteturas de embeddings distintas, permitindo testar a sensibilidade dos resultados à dimensionalidade e ao treinamento do modelo. O modelo Cohere v.3.0 (embed-multilingual-v3.0; Cohere, 2023), especializado em busca semântica e recuperação de informação, gera vetores de 1024 dimensões e foi estimado pelo pacote embedR (0.1.0; Wulff, 2025). O MPNET (paraphrase-multilingual-mpnet-base-v2; Reimers & Gurevych, 2019; Song et al., 2020), com 768 dimensões, é otimizado para detecção de paráfrases e foi executado localmente com o auxílio do pacote reticulate (1.44.1; Ushey et al., 2025). Por fim, a arquitetura OpenAI (text-embedding-3-large; OpenAI, 2024), com 3072 dimensões, representa o estado da arte em modelos globais de alta resolução e foi estimada pelo pacote openai (v.0.4.1; Rudnyskyi, 2023).

2.3. Engenharia de Variáveis (Features) e Modelagem Preditiva

Para mapear a relação entre pares de itens (variável independente) e sua correlação policórica humana (variável alvo), realizamos uma engenharia de atributos baseada na interação vetorial. Para cada par de itens, calculamos a Diferença Absoluta ($|v_1 - v_2|$), visando capturar a distância métrica entre os conceitos, e o Produto de Hadamard ($v_1 \odot v_2$), para capturar interações e conjunções lógicas entre as dimensões latentes. Todas as variáveis preditoras foram centradas e escalonadas (Z-score) antes do processamento. A escolha da Diferença Absoluta e do Produto de Hadamard baseia-se na literatura de Siamese Neural Networks e Sentence-BERT (Reimers & Gurevych, 2019). A diferença

absoluta captura a distância métrica entre os conceitos no hiper-espaço, enquanto o Hadamard (multiplicação elemento a elemento) captura a interação não-linear e a sobreposição de dimensões, servindo como um *proxy* matemático para a conjunção lógica de sintomas na mente do respondente.

Sobre esse conjunto de dados, aplicamos quatro algoritmos de aprendizado de máquina para testar as hipóteses H1 e H4, utilizando os pacotes caret (v.7.0.1; Kuhn, 2008), ranger (v.0.17.0; Marvin & Ziegler, 2017), party (v.1.3.18; Hothorn et al., 2006) e glmnet (v.4.1.8; Friedman et al., 2010), comparando-os a uma linha de base de similaridade de cosseno linear. Os modelos incluíram o Elastic Net, uma regressão linear regularizada (Lasso/Ridge) eficiente para seleção de variáveis em alta dimensionalidade; a Random Forest, um modelo de conjunto não-linear para capturar interações complexas; o XGBoost, baseado em *gradient boosting* sequencial para otimização de erros residuais; e a Árvore de Inferência Condicional (ctree), que prioriza a interpretabilidade e transparência (*Explainable AI* - XAI) por meio de testes de hipótese estatística para as divisões dos nós.

A robustez estatística foi aferida via validação cruzada ($10 - foldCV$) e predições *Out-of-Bag* (OOB). A significância do desempenho preditivo foi desenvolvida por meio de um teste de Y-randomization em que o vetor de correlações humanas foi aleatorizado em 50 iterações, servindo como uma linha de base de “caos” para garantir que a variância explicada (R^2) não fosse um artefato de *overfitting* ou memorização estatística. Adicionalmente, implementou-se um Teste de Permutação do Caos, treinando os modelos sob a hipótese nula (alvo embaralhado aleatoriamente), para assegurar que a acurácia observada transcendesse o ruído estatístico.

2.4. Validação de Construto e Isomorfismo Estrutural

Seguindo as diretrizes de Suárez-Álvarez et al. (2026), utilizou-se o procedimento de Pseudo Factor Analysis (PFA) para testar a H3 (Isomorfismo) e a H5 (Dominância Transdiagnóstica). As predições do melhor modelo, Elastic Net com *embeddings* da arquitetura Cohere, foram utilizadas para reconstruir uma Matriz de Correlação Sintética (21x21). Esta matriz foi submetida a uma Análise Fatorial Confirmatória (CFA) via pacote lavaan (v.0.6-20; Rosseel et al., 2025) e semTools (v.0.5-7; Jorgensen et al., 2025). Como critérios de ajuste satisfatório adotou-se valores de CFI e TLI $\geq 0,90$ (idealmente $> 0,95$), SRMR $< 0,08$ e RMSEA $< 0,08$ – com o limite superior do intervalo de confiança

de 90% não excedendo 0,10 (Hu e Bentler, 1999). Para o χ^2/df , valores abaixo de 3,0 foram considerados indicativos de bom ajuste (Kline, 2023), porém este não foi um ponto de corte. A fidedignidade foi avaliada pelo Ômega de McDonald (ω), adotando-se o ponto de corte de $> 0,70$ para consistência interna aceitável (McDonald, 1999). O isomorfismo estrutural foi investigado por meio de uma abordagem de modelagem competitiva, submetendo tanto as matrizes empíricas quanto as sintéticas aos seguintes modelos de mensuração:

1. DASS-21: Compararam-se o modelo de três fatores correlacionados (Depressão, Ansiedade e Estresse) e o modelo bifatorial (*p-factor* mais os três fatores específicos).
2. PANAS: Testou-se o modelo de dois fatores (Afetos Positivos e Negativos), com ajuste de carga cruzada para o item "Alerta" conforme especificidades da população brasileira (Nunes et al., 2019).
3. BDI-II e BAI: Testaram-se três estruturas competitivas: (a) dois fatores correlacionados (Depressão vs. Ansiedade; Beck et al., 1996); (b) quatro fatores correlacionados, separando sintomas cognitivo-afetivos de somático-fisiológicos para cada instrumento (Wang & Gorenstein, 2013; Steer et al., 1993); e (c) o modelo bifatorial hierárquico, visando isolar a dominância do *p-factor*.

2.5. Validade de Transferência e Explicabilidade (XAI)

A capacidade de generalização foi testada sob o paradigma de transferência *zero-shot* em que os modelos treinados exclusivamente na DASS-21 foram aplicados para prever matrizes de instrumentos com estruturas narrativas e construtos distintos – PANAS, BDI-II e BAI. Para mitigar a dependência estatística inerente ao *design pairwise* (em que um item participa de múltiplos pares), os p-valores de todas as correlações de transferência e etiquetas de XAI foram estimados via Simulações de Monte Carlo com 10.000 iterações, estabelecendo distribuições nulas empíricas para cada teste de hipótese. A transferência para a PANAS focou no domínio de Afetos Negativos, garantindo a paridade ontológica com o espectro de sofrimento da DASS-21.

Para verificar a racionalidade clínica dos modelos (H6), a explicabilidade do modelo foi auditada em dois níveis: (1) a importância global das dimensões via Elastic Net e (2) a lógica de decisão hierárquica via *ctree*. As dimensões matemáticas de maior peso foram interpretadas qualitativamente por meio de uma estratégia de triangulação

semântica, correlacionando as dimensões matemáticas a dois alvos: (a) 27 sondas emocionais com evidências de validade (Kambeitz et al., 2025) e (b) uma matriz de identidade dos itens do instrumento, visando identificar as âncoras clínicas específicas de cada nó decisório. Todas as associações e etiquetas semânticas foram verificadas via Simulações de Monte Carlo (10.000 iterações).

3. Resultados

3.0. Arquitetura Empírica de Referência

Antes de proceder à modelagem generativa via inteligência artificial, estabeleceu-se a Arquitetura Empírica de Referência utilizando os dados das amostras brasileiras. O objetivo desta etapa foi identificar os modelos de melhor ajuste para os instrumentos DASS-21, PANAS e o conjunto clínico BDI-II/BAI, servindo como o padrão-ouro (*ground truth*) para as simulações subsequentes.

Para a DASS-21, os resultados indicaram que o modelo bifatorial apresentou um adequado ajuste estatístico ($\chi^2[168] = 174,84; p = 0,343; CFI = 1,000; RMSEA = 0,013$). O fato de o qui-quadrado não ser significativo sugere que a estrutura de um fator geral de sofrimento (*distress*) sobreposto a três fatores específicos é a representação exata da variância dos dados. Este achado é crucial, pois levanta evidências de validade para o modelo bifatorial da DASS-21 como uma base de treinamento psicometricamente “pura” para os modelos de linguagem.

Na análise do conjunto BDI-II e BAI, observou-se uma tensão teórica fundamental. Embora o modelo de 4 fatores correlacionados (separando sintomas cognitivos e somáticos de cada transtorno) tenha apresentado o melhor ajuste absoluto ($RMSEA = 0,037; CFI = 0,985$), o modelo bifatorial revelou a dinâmica de dominância do fator geral. Ao isolar o Fator Geral de Psicopatologia (*p-factor*), observou-se que sua fidedignidade composta foi robusta ($\omega = 0,87$), enquanto a variância remanescente nos fatores específicos foi significativamente reduzida (ω entre 0,15 e 0,24).

Este fenômeno de exaustão da variância pelos fatores gerais indica que, embora o ser humano consiga distinguir nuances fenomenológicas (corpo vs. mente), a força motriz das respostas reside em um núcleo comum de sofrimento transdiagnóstico (Kutov et al., 2017). A Tabela 1 sumariza os índices de ajuste e fidedignidade que compõem este gabarito empírico.

Tabela 1

Índices de Ajuste Global e Fidedignidade dos Modelos de Mensuração para as Amostras Empíricas

Modelos de Mensuração	χ^2/df	p	CFI	$RMSEA$ [IC 90%]	$SRMR$	ω
DASS-21 com 3 Fatores Teórico	1.63	<.001	0.995	0.049 [0.039 - 0.059]	0.057	Dep: .92; Anx: .89; Est: .90
DASS-21 Bifatorial (p-factor)	0.94	.343	1.000	0.013 [0.000 - 0.031]	0.045	FG: .86; Dep: .33; Anx: .18; Est: .08
PANAS 2 Fatores (Ajustado*)	3.80	<.001	0.982	0.078 [0.072 - 0.085]	0.072	Pos: .93; Neg: .92
BDI-II + BAI 2 Fatores (Separados)	3.95	<.001	0.982	0.040 [0.039 - 0.042]	0.056	BDI: .91; BAI: .92
BDI-II + BAI 2 com 4 Fatores	3.46	<.001	0.985	0.037 [0.035 - 0.038]	0.054	BDI_C: .85; BDI_S: .82; BAI_C: .86; BAI_S: .84
BDI-II + BAI 2 Bifatorial	4.73	<.001	0.979	0.045 [0.044 - 0.047]	0.063	FG: .87; (Esp: .15 a .24)

*Nota. PANAS ajustado com carga cruzada no item “Alerta” conforme especificidades da amostra brasileira (Nunes et al., 2019). χ^2/df = qui-quadrado normatizado (razão entre o qui-quadrado e os graus de liberdade); p = valor de significância estatística; CFI = *Comparative Fit Index*; $RMSEA$ = *Root Mean Square Error of Approximation*; $IC90\%$ = intervalo de confiança de 90% para o $RMSEA$; $SRMR$ = *Standardized Root Mean Square Residual*; ω = coeficiente ômega de McDonald. Dep = depressão, Anx = Ansiedade e Est = estresse. Para o modelo BDI-II + BAI, as subdimensões referem-se a Cognitiva (C) e Somática (S).

3.1. Benchmarking de Modelos e Isomorfismo Estrutural Sintético

3.1.1. Replicação Interna

A aplicação de algoritmos de aprendizado de máquina sobre as interações vetoriais dos *embeddings* resultou em um incremento de performance em relação ao *baseline* de cosseno puro. O modelo OpenAI + Elastic Net atingiu variância explicada de 69,3% (R^2),

com RMSE = 0,068. Observou-se uma estabilização da performance em torno de 70%, independentemente da arquitetura de larga escala utilizada. Como demonstrado na Tabela 2, o Elastic Net apresentou maior robustez transversal, enquanto modelos baseados em árvores demonstraram maior variabilidade nas tarefas de transferência. O teste de Y-randomization (caos) resultou em acurácia nula ($r \approx 0$), levantando validade para a existência de um sinal semântico sistemático nos dados originais.

Embora a arquitetura OpenAI tenha atingido o maior pico de variância explicada na fase de treinamento, os modelos baseados em Cohere e MPNet revelaram especializações semânticas complementares e cruciais para a validade de transferência – o que será mais esmiuçado no subtópico 3.1.2. No que tange aos algoritmos de aprendizado de máquina, o Elastic Net consolidou-se como o modelo mais robusto e estável entre todas as arquiteturas. Sua superioridade na generalização sugere que a regularização inerente a este algoritmo é fundamental para filtrar o ruído sintático dos *embeddings* e capturar o sinal psicométrico latente, superando modelos de maior complexidade algorítmica, como Random Forest e XGBoost, que demonstraram maior tendência ao *overfitting* nas tarefas de transferência.

A Tabela 2 sumariza o desempenho preditivo dos modelos em distintos de complexidade, sendo 1) a replicação interna da DASS-21; 2) a abstração emocional para o fator de Afetos Negativos da PANAS; e, por fim, 3) a transferência estrutural para a sintomatologia clínica (BDI-II e BAI).

Tabela 2

Desempenho Preditivo e Validade de Transferência dos Modelos de IA

Embedding	Modelo	R ² (DASS)	RMSE (DASS)	MAE (DASS)	PANAS (r _{negativo})	BDI/BAI (r _{total})
Cohere (1024d)	Linear (Cosseno)	0,137	N/A	N/A	0,260***	0.288***
	Elastic Net	0,659	0,068	0,053	0,530***	0.352***
	ctree	0,648	0,069	0,053	0,500***	-0.019
	Random Forest	0,693	0,073	0,058	0,343*	0.236***
	XGBoost	0,572	0,077	0,061	0,370*	0.119***
MPNET (768d)	Linear (Cosseno)	0,308	N/A	N/A	0,258***	0.288***
	Elastic Net	0,690	0,066	0,052	-0,061	0.462*
	ctree	0,600	0,074	0,058	-0,162	0.224***
	Random Forest	0,674	0,076	0,060	-0,088	0.432***

OpenAI (3072d)	XGBoost	0,630	0,071	0,056	0,376	0.292***
	Linear (Cosseno)	0,188	N/A	N/A	0,433***	0.188***
	Elastic Net	0,691	0,068	0,054	0,403**	0.336***
	ctree	0,476	0,082	0,061	0,424**	0.058
	Random Forest	0,652	0,079	0,061	0,229	0.357***
	XGBoost	0,617	0,073	0,057	-0,074	0.288***

Nota. R^2 = coeficiente de determinação; RMSE = *Root Mean Square Error*; MAE = *Mean Absolute Error*; r = correlação de Pearson. Significância (p) estimada via testes de permutação de Monte Carlo (10.000 iterações) para mitigar a dependência estatística entre pares de itens. *** $p_{perm} < 0,001$; ** $p_{perm} < 0,01$; * $p_{perm} < 0,05$. Ctree= Árvore de Inferência Condicional.

O teste de Y-randomization revelou que, sob condições de aleatoriedade total (caos), a capacidade preditiva de todos os algoritmos colapsou para níveis nulos ($r \approx 0$). Notavelmente, os modelos de Elastic Net falharam em extrair qualquer coeficiente significativo do ruído, resultando em modelos nulos.

3.1.2. Validade de Transferência e a Assimetria da Cognição Incorporada

Embora o modelo OpenAI tenha apresentado o maior R^2 na fase de treino, a arquitetura de *embeddings* Cohere demonstrou maior robustez na generalização trans-instrumento. O Cohere alcançou o melhor equilíbrio preditivo entre a PANAS e o modelo bifatorial BDI + BAI, mantendo uma predição da matriz de correlação da DASS-21 altamente competitiva ($R^2 = 0,652$). Por essa razão, o Cohere foi selecionado como o modelo de referência para a reconstrução estrutural.

Ao se gerar a matriz sintética de correlações, observou-se uma relação estrutural entre a CFA sintética para o modelo bifatorial, com um ajuste estatístico superior ao observado aos dados humanos ($\chi^2/df = 1,14$; $CFI = 0,992$; $TLI = 0,991$; $RMSEA = 0,024$; $SRMR = 0.041$). Mais importante ainda, a hierarquia das cargas fatoriais (*loadings*) demonstrou uma convergência quase absoluta entre humanos e IA, com uma correlação de $r = 0,98$ ($p_{perm} < 0,001$).

Na transferência para a escala PANAS, modelos de larga escala (Cohere/OpenAI) foram superiores ($r = 0,53$). Entretanto, na transferência para sintomas clínicos (BDI-

II/BAI), o modelo MPNet + Elastic Net demonstrou superioridade ($r = 0,46; p_{perm} < 0,001$), indicando que o paralelismo sintático entre frases de sintomas favorece modelos treinados especificamente para similaridade de sentenças.

A análise detalhada da transferência para o BDI-II e BAI indicou que a IA demonstrou alta precisão na reconstrução da rede de sintomas de depressão ($r = 0,46; p_{perm} < 0,001$) mas encontrou um limite nos sintomas de ansiedade somática do BAI ($r = 0,23; p_{perm} < 0,01$).

Destaque-se que, ao submeter as matrizes sintéticas transferidas à análise fatorial, a IA corroborou a decisão estrutural dos humanos, preferindo o modelo Bifatorial sobre o de dois fatores correlacionados ($\Delta CFI = 0,082$). Todavia, a IA tendeu a uma unidade ontológica, colapsando a maior parte da variância no Fator Geral ($\omega_{FG} = 0,97$), com fatores específicos residuais próximos a zero. Este achado sugere que, no nível puramente semântico, a psicopatologia é interpretada como um núcleo unificado de sofrimento.

A análise da Tabela 3 revela que um padrão interessante. Enquanto na DASS-21 a IA recuperou a hierarquia de sintomas com precisão quase absoluta ($r = 0,98$), na transferência para o modelo bifatorial BDI/BAI observou-se uma queda, mas ainda estatisticamente robusta, na convergência das cargas ($r = 0,40$). Notavelmente, em ambos os casos, a IA demonstrou uma tendência à supra-identificação do Fator Geral ($\omega > 0,95$).

Tabela 3

Comparação entre as Análises Fatoriais Confirmatórias Empíricas e Sintéticas para os Modelos Bifatoriais da DASS-21 e do BDI-II somado à BAI

<i>Teste / Origem</i>	<i>Modelo</i>	χ^2/df	<i>CFI</i>	<i>TLI</i>	<i>RMSEA [IC 90%]</i>	<i>SRMR</i>	<i>(FG)</i>	<i>r*</i>
DASS-21								
<i>Humano</i>	Bifatorial	1,04	1,000	1,000	0,013 [0,000 - 0,031]	0,045	0,86	-
<i>IA</i>	Bifatorial	1,14	0,992	0,991	0,024 [0,000 - 0,037]	0,041	0,96	0,98
BDI + BAI								
<i>Humano</i>	Bifatorial	4,73	0,979	0,976	0,045 [0,044 - 0,047]	0,063	0,87	-
<i>IA</i>	Bifatorial	3,01	0,891 ²	0,870	0,066 [0,063 - 0,069]	0,033	0,97	0,40

² Marsh et al. (2004) argumentam que em contextos de alta complexidade ou dados novos, valores próximos a 0,90 já demonstram uma captura substancial da estrutura latente.

Nota: χ^2/df = qui-quadrado normatizado (razão entre o qui-quadrado e os graus de liberdade); p = valor de significância estatística; CFI = *Comparative Fit Index*; $RMSEA$ = *Root Mean Square Error of Approximation*; $IC90\%$ = intervalo de confiança de 90% para o RMSEA; $SRMR$ = *Standardized Root Mean Square Residual*; ω_{FG} = Ômega de McDonald do Fator Geral. r^* = representa a correlação de Pearson entre as cargas fatoriais padronizadas (*loadings*) humanas e sintéticas validadas via permutação. χ^2/df dos modelos DASS-21 foram não significativos.

3.1.3. Granularidade da Transferência: Decomposição por Domínios Clínicos

A validade de transferência decomposta entre os instrumentos BDI-II e BAI, bem como seus respectivos subfatores teóricos, revelou uma assimetria de legibilidade semântica. A IA demonstrou uma capacidade significativamente superior em reconstruir a rede da depressão em comparação à ansiedade somática. Enquanto o modelo atingiu uma correlação robusta e significativa para o BDI-II total ($r = 0,46, p_{perm} < 0,001$), o desempenho no BAI total foi modesto ($r = 0,23, p_{perm} < 0,001$). A análise granular via testes de permutação evidenciou que a depressão mantém estabilidade estrutural tanto em seu núcleo Cognitivo-Afetivo ($r = 0,47, p_{perm} < 0,001$) quanto no Somático-Vegetativo ($r = 0,54, p_{perm} < 0,001$).

Em contrapartida, embora a ansiedade apresente um sinal estatístico no nível do instrumento total ($r = 0,23, p_{perm} < ,001$), esse sinal dilui-se e perde significância ao nível dos subfatores Subjetivo-Cognitivo ($r = 0,19; ns$) e Somático-Fisiológico ($r = 0,15; ns$).


3.2. Isomorfismo Estrutural e Validade de Construto Sintética (DASS-21)

A reconstrução das arquiteturas fatoriais via *Pseudo Factor Analysis* (PFA) revelou uma convergência entre as matrizes sintéticas e empíricas. Na DASS-21, o modelo bifatorial sintético apresentou ajuste superior ao humano ($\chi^2/df = 1,14; CFI = 0,992; RMSEA = 0,024$). A hierarquia das cargas fatoriais demonstrou isomorfismo quase absoluto, com $r = 0,98$ ($p < 0,001$) no modelo de três fatores (Figura 1) e $r = 0,99$ ($p < 0,01$) no fator geral do modelo bifatorial (Figura 2).

Na transferência para o conjunto BDI-II/BAI, a IA corroborou a decisão estrutural dos humanos, apresentando melhor ajuste no modelo Bifatorial ($CFI = 0,891$; $SRMR = 0,033$) em comparação ao modelo de fatores correlacionados. No entanto, observou-se uma queda na convergência das cargas fatoriais em relação à base de treinamento ($r = 0,40$; $p < 0,01$), acompanhada por uma tendência de supra-identificação do Fator Geral ($\omega_{FG} = 0,97$), conforme detalhado na Tabela 3.

Figura 1

Comparação entre as cargas padronizadas da amostra humana e as cargas estimadas pela matriz sintética de Elastic Net + *embeddings* da arquitetura Cohere




Nota. i = item.

Ademais, em consonância com a H5, exploramos a natureza transdiagnóstica da escala por meio de um modelo bifatorial. Tanto nos dados humanos quanto nos sintéticos, o modelo bifatorial emergiu como a melhor representação estrutural (Sintético: $\chi^2[170] = 143,65$, $p = 0,930$, $CFI = 1,000$, $RMSEA = 0,000$; Humanos: $\chi^2[170] = 178,03$, $p = 0,321$, $CFI = 1,000$, $RMSEA = 0,014$). A análise de fidedignidade composta revelou a dominância do Fator Geral de sofrimento psíquico, com um Ômega de McDonald de 0,89 na matriz da IA e 0,87 na matriz humana. A correlação entre as cargas fatoriais no Fator Geral foi de $r = 0,99$ ($p < 0,01$; Figura 2).

Figura 2

Comparação entre as cargas padronizadas da amostra humana e as cargas estimadas pela matriz sintética de Elastic Net + *embeddings* da arquitetura Cohere no Fator Geral



3.3. Inteligência Artificial Explicável (XAI): Auditoria da Gramática Clínica

3.3.1. Decomposição do Espaço Semântico no modelo Elastic Net

A análise de importância das variáveis no modelo Elastic Net revelou que a predição da psicopatologia é governada por um subconjunto de dimensões semânticas. Observou-se uma queda acentuada de peso após os primeiros preditores (Figura 3), indicando uma estrutura parsimoniosa. A interpretação clínica dessas dimensões permitiu identificar os eixos lógicos que sustentam o modelo.

O primeiro eixo, que verificamos ser de Regulação Homeostática vs. Desânimo (V1715), é responsável pelo maior peso preditivo do modelo (Importância = 100), esta interação de Hadamard apresentou uma correlação bimodal significativa com as sondas de calma ($r = 0,51, p_{perm} = 0,018$) e tédio ($r = -0,47, p_{perm} = 0,029$). A análise baseada em itens confirmou esta natureza, revelando uma associação negativa significativa com o item i13 (Senti-me deprimido e sem ânimo; $r = -0,46, p_{perm} = 0,047$).


O segundo eixo, de Estabilidade Afetivo-Temporal (V1044), revelou uma associação negativa com as sondas de nostalgia ($r = -0,54, p_{perm} = 0,011$) e tristeza ($r = -0,48, p_{perm} = 0,026$). Paralelamente, demonstrou uma associação positiva significativa com o item i19 (Sabia que meu coração estava alterado; $r = 0,43, p_{perm} = 0,047$).

O quarto eixo, relacionado ao Núcleo de Dor Afetiva e Vazio Existencial (V1910) foi identificado como o terceiro pilar semanticamente estável, esta dimensão correlacionou-se diretamente com a sonda de tristeza ($r = 0,49, p_{perm} = 0,024$) e apresentou a mais forte associação com o item i21 (Senti que a vida não tinha sentido; $r = 0,58, p_{perm} = 0,047$). Enquanto as dimensões anteriores estabelecem os eixos de regulação e estabilidade fisiológica, a V1910 fornece o componente de afetividade negativa pura.

Embora outras variáveis, como a V1115, apresentem relevância estrutural para a acurácia métrica do modelo, suas associações semânticas com as sondas não atingiram o critério de significância estatística via permutação ($p > 0,05$). Em suma, a XAI demonstra que o modelo Elastic Net prioriza a regulação emocional (calma vs. desânimo) e a polaridade entre ativação somática e vazio existencial como os preditores universais.

Figura 3

Importância Relativa das Dimensões Semânticas no Modelo Elastic Net com os *embeddings* da arquitetura Cohere



Nota. Os códigos no eixo y (e.g., V1715) representam dimensões do espaço latente dos *embeddings* identificadas como preditores nucleares da covariação humana. Importância escalonada de 0 a 100 baseada nos coeficientes de regressão regularizada.

3.3.2. Arquitetura da Decisão Semântica (ctree)


Os resultados da Árvore de Inferência Condicional com a arquitetura Cohere demonstram que mesmo um modelo interpretável de árvore única é capaz de capturar a complexidade do fenômeno psicopatológico, atingindo uma acurácia de $R^2 = 0,65$. A análise da estrutura da árvore (Figura 4) revelou que a variável de maior importância hierárquica, situada no Nó 1, é a dimensão vetorial V1528, que atua como um Eixo Somático-Cognitivo ($p < 0,001$). A função diagnóstica deste nó foi confirmada por testes de permutação, apresentando associação significativa com o sintoma somático nuclear de dificuldade de respirar ($i4; r = 0,53; p_{perm} = 0,047$). Embora o modelo aponte itens de natureza subjetiva no polo oposto, como o medo sem motivo ($i20; r = -0,50$), esta associação não atingiu o critério de significância estatística ($p_{perm} = 0,09$), sugerindo que a soberania decisória do Nó 1 reside na identificação da ativação fisiológica visceral.

Para os itens de natureza predominantemente cognitiva (flanco esquerdo), a IA utiliza a dimensão V1915 (Anedonia Depressiva) como o principal refinamento preditivo. Para esta dimensão foi levantada dupla evidência de validade via permutações: por meio de sondas emocionais de tédio ($r = 0,62; p_{perm} = 0,002$) e tristeza ($r = 0,56; p_{perm} = 0,007$), e por sua capacidade de isolar o núcleo melancólico através da exclusão significativa de sintomas de pânico social ($i9; r = -0,50; p_{perm} = 0,047$). A presença deste nó demonstra que a IA isolou a perda de vitalidade como o diferencial crítico para prever a covariação em quadros depressivos, distinguindo a ausência de desejos ($i10$) e o desânimo ($i13$) de estados de agitação ou preocupação social.

No flanco direito da árvore, em que se concentram as predições de correlação mais elevadas, o modelo utiliza a dimensão V385 (Temor de Antecipação) para mapear sintomas de alarme agudo. Sua validade semântica foi levantada pela associação com conceitos de assombro (*awe*; $r = 0,52; p_{perm} = 0,015$) e urgência (*craving*; $r = 0,43; p_{perm} = 0,049$), sendo ancorada novamente pelo marcador somático de dispneia ($i4; r = 0,53; p_{perm} = 0,047$). O modelo atribui as maiores predições de associação ($\bar{r} \approx 0,70$) a pares de itens que compartilham essa carga de urgência clínica. Intermediando esses eixos, a dimensão V1162 atua como um divisor de Reatividade Emocional, separando sintomas de reatividade aguda de estados de tensão crônica.

Figura 4

Mapeamento hierárquico das regras lógicas utilizadas pela IA para prever a correlação entre sintomas



Nota. Conditional Inference Tree. Os boxplots nos nós terminais representam a distribuição das correlações humanas reais previstas pelo modelo.

Em suma, a “mente” do modelo reconstruiu os pilares da psicopatologia através de uma triagem lógica rigorosa fundamentada em p-valores robustos: (1) a distinção entre corpo e mente; (2) a mensuração da perda de vitalidade (Anedonia) para o espectro depressivo; e (3) a avaliação da intensidade do temor para o espectro da ansiedade..

4. Discussão

Os achados deste estudo demonstram que a estrutura da psicopatologia não é apenas um subproduto de padrões de resposta observados em populações clínicas, mas uma propriedade emergente codificada na semântica dos sintomas (Kambeitz et al., 2025). A convergência observada entre a covariação de respostas humanas e o espaço latente dos *Large Language Models* (LLMs) sugere uma organização racional e incorporada do sofrimento psíquico na linguagem, passível de mapeamento computacional robusto [H1].

4.1. O Espelho Platônico e o Teto Semântico

A estabilização do coeficiente de determinação em aproximadamente 70% ($R^2 \approx 0,69$) entre diferentes arquiteturas define o que propomos como o Teto Semântico da Psicopatologia. Este limite sugere que a linguagem é capaz de explicar a maior parte da estrutura da doença mental, mas deixa uma lacuna residual de variância não-explicada (30%). Este componente residual provavelmente reflete domínios não-semânticos, relacionados à subjetividade fenomenológica pura e à variabilidade biológica individual que a codificação textual não consegue capturar integralmente. Essa interpretação é reforçada pelo teste de Y-randomization, que demonstrou que a acurácia do modelo colapsa na ausência de estrutura semântica sistemática, provando que o 'teto' observado não é um artefato algorítmico, mas o limite real da informação clínica depositada na linguagem.

Contudo, o fato de a matriz sintética ter apresentado um ajuste estatístico superior ao modelo humano na DASS-21 (χ^2 não significativo; $p = 0,085$) reforça a viabilidade da IA como um método de calibração pré-empírica. Nossos resultados de isomorfismo ($r = 0,98$ nas cargas fatoriais) indicam que o aprendizado de máquina atua como um Espelho Platônico [H3]: recupera a estrutura idealizada do construto ao filtrar ruídos conjunturais, tais como fadiga, viés de desejabilidade ou erros de interpretação – inerentes ao dado empírico, levantando evidências de validade para a lógica interna do instrumento antes mesmo da coleta de dados em larga escala.

Esse fato é mais um indício de que o ponto principal de distinção entre a matriz sintética de relação entre os itens e a matriz com os dados empíricos os dados humanos estão intimamente conectados ao corpo humano – ou a ausência dele. Desta forma, a Psicometria Generativa se comporta como uma psicometria “desincorporada”, e os mais de 30% de variância que ela não explica muito provavelmente são relacionados ao aspecto biológico.

É importante ressaltar que o Teto Semântico de 70% não deve ser atribuído exclusivamente às limitações da inteligência artificial. Em psicometria, a variância do erro e a instabilidade temporal das respostas humanas impõem um limite natural à variância explicável.

4.2. A Assimetria Depressão-Ansiedade e a Cognição Incorporada

A análise de transferência revelou um achado teórico contundente neste estudo: a assimetria semântica entre depressão e ansiedade. Enquanto a IA demonstrou precisão na reconstrução da rede de sintomas depressivos ($r = 0,46$), atingindo seu pico de performance no subfator **Somático-Vegetativo** ($r = 0,54$), ela encontrou um "limite sensorial" nos sintomas de ansiedade do BAI ($r = 0,23$), falhando em atingir significância estatística em nível granular. Clinicamente, isso levanta evidências de validade para a semiologia psicopatológica clássica (Jaspers, 1913/1997), demonstrando que a base da organização diagnóstica repousa sobre o substrato fenomenológico de onde o sintoma emana.

Este achado confirma o limite da Cognição Incorporada [H7], mas sob a nova perspectiva de que os LLMs, embora desprovidos de um corpo biológico, capturam o rastro linguístico da incorporação de formas distintas. A depressão, mesmo em seus componentes somáticos (sono, apetite, energia), é construída sobre narrativas biológicas estáveis e altamente coesas na linguagem clínica. A IA “entende” o corpo deprimido porque ele é descrito como uma exaustão lógica do sistema. Em contrapartida, a ansiedade capturada pelo BAI é composta por sensações viscerais agudas e assistemáticas (e.g., dormência, calafrios, ondas de calor). A falha estrutural da IA nesses subdomínios indica que a ansiedade somática retém um núcleo sensorial bruto que escapa à simulação puramente proposicional.

A discrepância observada entre as matrizes sintéticas e empíricas fornece indícios de que o ponto de divergência estrutural reside na conexão com o corpo biológico, ou na ausência dele. Desta forma, a Psicometria Generativa se manifesta como uma psicometria desincorporada. Enquanto ela recupera com fidelidade a estrutura idealizada dos construtos (o nível ontológico), os mais de 30% de variância não explicada (o Teto Semântico) representam o aspecto mais residual da representação biológico. Este resíduo abrange a variabilidade fenomenológica e a reatividade fisiológica que o texto, embora tente descrever, não consegue simular integralmente. Assim, a IA identifica que a estrutura da psicopatologia na linguagem é uma “Psicometria da Ideação”, excepcionalmente capaz de mapear fenômenos ideativos, mas limitada pela ausência de experiência sensorial primária.

4.3. Especialização Sintática e a Unidade Ontológica do p-factor

A dissociação observada entre os modelos MPNet e Cohere revela uma distinção crítica entre precisão sintática e abstração conceitual [H4]. O MPNet, por ser otimizado para similaridade de sentenças, superou os modelos globais na transferência para sintomas clínicos ($r = 0,46$), capturando o paralelismo narrativo entre as escalas. Em contraste, o Cohere e a OpenAI demonstraram superioridade na transferência para afetos abstratos (PANAS; $r = 0,53$). Isso sugere que a Generalização Trans-Instrumento [H2] é possível, mas sua eficiência é moderada pela arquitetura do embedding em relação à natureza narrativa do alvo.

Independentemente da arquitetura, a convergência para a superioridade do modelo bifatorial reforça as teorias modernas da psicopatologia dimensional, como o HiTOP (Kotov et al., 2017) [H5]. A dominância do Fator Geral (FG) no espaço semântico da IA, evidenciada pelo colapso da variância nos fatores específicos ($\omega_{FG} = 0,97$), indica que muitas distinções diagnósticas atuais podem possuir uma natureza mais taxonômica do que ontológica. Para a IA, assim como para os dados empíricos, a separação entre ansiedade e depressão é uma sutileza linguística de um núcleo comum e unificado de sofrimento (*distress*). O colapso dos fatores específicos na IA ($\omega \approx 0$) indicam que não há diferença real entre estar triste e estar ansioso para a IA – primariamente ontológica. Para o humano, o que separa esses estados, de forma pouco confiável, é a sensação somática – fenomenológica. Sem o corpo, a IA “vê” apenas a unidade (o p-factor).

Deve-se considerar o risco de circularidade ontológica, uma vez que os LLMs são treinados em vastos *corpora* que incluem manuais clínicos e literatura acadêmica. Nesse sentido, a IA pode estar replicando a estrutura teórica consolidada na linguagem científica em vez da experiência fenomenológica bruta. Contudo, para fins de calibração pré-empírica de instrumentos, essa característica é uma virtude metodológica, pois permite recuperar a “alma teórica” do teste de forma purificada antes da coleta de dados com pacientes reais.

A queda de performance na transferência para a PANAS, em contraste com o sucesso no BDI-II/BAI, sugere que a Psicometria Generativa é sensível ao paralelismo narrativo. Frases completas de sintomas clínicos permitem uma extração de *embeddings* mais rica em contexto do que adjetivos isolados, indicando que a formulação sintática dos itens é um moderador crítico da validade de transferência em modelos de linguagem.

4.4. Explicabilidade e Psicometria Generativa Auditável

O desempenho de modelos interpretáveis (Elastic Net e *ctree*) em patamares equivalentes a modelos de “caixa-preta” (Random Forest, XGBoost) representa um avanço para a aplicação ética da IA na saúde mental. A identificação do Eixo Somático-Cognitivo (V1528) como o nó primário de decisão na *ctree* e a centralidade do Núcleo de Desvitalização (V1715) no Elastic Net indicam que a IA não opera por associações estatísticas espúrias. Ela “raciocina” por meio de distinções semiológicas fundamentais tais como corpo vs. mente e vitalidade vs. Anedonia [H6]. A identificação do marcador somático de dispneia (i4) e do núcleo melancólico (i13 e i21) como âncoras estatísticas dos nós decisórios indica que a IA captura a hierarquia diagnóstica dos sintomas além de utilizar a proximidade lexical. Este achado é mais uma evidência que os aspectos homológicos que encontramos neste estudo se relacionam à parte incorporada da cognição – ou da aproximação conceitual dela. Ou seja, como a IA não tem corpo humano precisa desse eixo para “entender” os humanos, fazendo com que essa distinção seja um ponto fulcral da linguagem clínica.

Esta transparência atende à demanda por *Explainable AI* (XAI) na saúde (Suárez-Álvarez et al., 2026), movendo o uso de LLMs para uma ferramenta auditável e clinicamente fundamentada. Demonstramos que a Psicometria Generativa pode guiar o desenvolvimento de novos instrumentos, permitindo que pesquisadores testem a validade estrutural de itens *in silico* antes de submetê-los ao crivo empírico, unindo precisão computacional à transparência clínica.

5. Considerações finais

Os achados deste estudo estabelecem uma nova fronteira para a ciência das medições de construtos ao demonstrar que a estrutura da psicopatologia é uma propriedade emergente, codificada e recuperável através da semântica da linguagem. Ao integrar Large Language Models (LLMs) à modelagem psicométrica, evidenciamos que a inteligência artificial é capaz de indicar a arquitetura teórica de construtos complexos, muitas vezes revelando uma estrutura mais nítida do que aquela obtida em amostras empíricas tradicionais.

Um importante achado é que a linguagem humana transporta o rastro da experiência física, mas a simulação desincorporada falha em replicar a reatividade fisiológica aguda. Esse limite pode atuar como uma ferramenta de diagnóstico ontológico,

permitindo-nos mensurar o quanto de um transtorno mental é construído narrativamente e o quanto reside na biologia visceral.

Do ponto de vista metodológico, o sucesso da Pseudo Factor Analysis (PFA) e a estabilidade do modelo Elastic Net consolidam a viabilidade da Inteligência Artificial para a calibração pré-empírica de instrumentos no contexto brasileiro. Inaugura-se um fluxo de trabalho em que pesquisadores podem testar a validade estrutural e a hierarquia de indicadores de novos itens *in silico*, identificando falhas de isomorfismo ou redundâncias semânticas antes de submeter participantes humanos a coletas de dados onerosas.

A convergência entre a alta acurácia preditiva e a explicabilidade (XAI) rompe com o paradigma da “caixa-preta” na saúde mental. Ao provar que o modelo “raciocina” sobre eixos semiológicos fundamentais, como o Somático-Cognitivo, este estudo fundamenta uma Psicometria Generativa auditável. Mais do que uma ferramenta de automação, a Inteligência Artificial passa a atuar como um colaborador analítico, capaz de oferecer um conhecimento profundo sobre a constituição dos instrumentos anterior à aplicação, unindo a precisão computacional ao rigor da clínica tradicional.

Limitações e Estudos Futuros

Este estudo apresenta limitações que delimitam o escopo da Psicometria Generativa. O uso de LLMs treinados em vasta literatura acadêmica impõe o risco de circularidade ontológica, em que a IA pode estar recuperando o conhecimento teórico consolidado sobre os instrumentos em vez de simular a experiência fenomenológica bruta, ainda que o sucesso da transferência *zero-shot* entre instrumentos de naturezas distintas sugere que há uma inferência semântica real e generalizável em jogo.

Embora a amostra humana de treinamento ($N = 259$) tenha se mostrado suficiente para gerar modelos que generalizam para grandes bancos de dados internacionais ($N = 1.957$), a estabilidade da verdade fundamental (*ground truth*) em modelos de alta dimensionalidade deve ser testada futuramente com bases de calibração ainda mais amplas.

A atribuição da variância residual de 30% à Lacuna Somática permanece uma inferência teórica carecendo de explicações alternativas, como o erro de medida inerente aos dados humanos, nuances culturais da língua portuguesa ou limitações intrínsecas da arquitetura dos algoritmos, não podem ser descartadas. Além disso, observou-se uma

tendência da IA à unidade ontológica, superestimando o Fator Geral (*p-factor*) em detrimento das nuances fenomenológicas específicas. Por fim, embora o uso de testes de permutação tenha mitigado a dependência estatística do *design pairwise*, o emprego de modelos multinível em estudos futuros poderia oferecer um controle ainda mais refinado sobre os efeitos específicos de cada item.

Essas limitações, contudo, não invalidam a utilidade do método como uma ferramenta de calibração pré-empírica, mas balizam as condições de contorno para o seu uso ético e tecnicamente rigoroso. Futuras pesquisas devem investigar se modelos treinados em *corpora* puramente médicos ou descrições fenomenológicas de primeira pessoa podem reduzir a lacuna identificada. Adicionalmente, a aplicação deste protocolo em diferentes culturas e idiomas permitirá verificar se o isomorfismo observado é uma lei universal da linguagem ou se sofre variações sociolinguísticas significativas.

Ressalta-se que os procedimentos de Psicometria Generativa não substituem o julgamento clínico ou a resposta humana, mas oferece uma lente poderosa para investigar a arquitetura dos construtos de forma pormenorizada e livre de ruídos conjunturais. Ao unir alta precisão computacional à transparência semiológica e auditável, este trabalho soma-se aos esforços contemporâneos para desbravar novas fronteiras na construção de instrumentos e na compreensão da estrutura profunda do sofrimento psíquico na era da inteligência artificial.

6. Referências

Anunciação, L. (2022, January 12). *Supplementary materials for published paper:*

Depression and anxiety symptoms in a representative sample of undergraduate students in Spain, Portugal, and Brazil. Retrieved from <https://osf.io/xpvbg>

Aparecido, T. D. D., Carrillo, A., Camargo, C. Q., & Stella, M. (2025). Benchmarking Psychological Lexicons and Large Language Models for Emotion Detection in Brazilian Portuguese. *AI*, 6, 249. <https://doi.org/10.3390/ai6100249>

Barsalou, L. W. (2008). Grounded cognition. *Annual Review of Psychology*, 59, 617–645. <https://doi.org/10.1146/annurev.psych.59.103006.093639>

- Bisk, Y., Holtzman, A., Jesse, J., Mei, M., & Choi, Y. (2020). Experience Grounds Language. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 8718–8735. <https://doi.org/10.18653/v1/2020.emnlp-main.703>
- Beck, A. T., Steer, R. A., & Brown, G. K. (1996). *Manual for the Beck Depression Inventory-II*. San Antonio, TX: Psychological Corporation.
- Beck, A. T., Epstein, N., Brown, G., & Steer, R. A. (1988). An inventory for measuring clinical anxiety: Psychometric properties. *Journal of Consulting and Clinical Psychology*, 56(6), 893–897. <https://doi.org/10.1037/0022-006X.56.6.893>
- Cohere. (2023, November 2). *Introducing Embed v3: A new state-of-the-art for semantic search*. <https://cohere.com/blog/introducing-embed-v3>
- Cunha, J. A. (2001). *Manual da versão em português das Escalas Beck*. São Paulo: Casa do Psicólogo.
- Dalgalarondo, P. (2018). *Psicopatologia e semiologia dos transtornos mentais* (3^a ed.). Artmed Editora.
- Fang, N. Q., & Oberski, D. L. (2022). Evaluating the construct validity of text embeddings with application to survey questions. *EPJ Data Science*, 39(39). <https://doi.org/10.1140/epjds/s13688-022-00353-7>
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22. <https://doi.org/10.18637/jss.v033.i01>
- Galton, F. (1884). Measurement of character. *The Fortnightly Review*, 36, 179–185.
- Garrido, L., Russell-Lasalandra, L. L., & Golino, H. (2025, December 30). *Estimating Dimensional Structure in Generative Psychometrics: Comparing PCA and Network*

Methods Using Large Language Model Item Embeddings.

https://doi.org/10.31234/osf.io/2s7pw_v1

Ghassemi, M., Oakden-Rayner, L., & Beam, A. L. (2021). The false hope of current approaches to explainable artificial intelligence in health care. *The Lancet. Digital health*, 3(11), e745–e750. [https://doi.org/10.1016/S2589-7500\(21\)00208-9](https://doi.org/10.1016/S2589-7500(21)00208-9)

Hommel, B. E., & Arslan, R. C. (2025). Language models accurately infer correlations between psychological items and scales from text alone. *Advances in Methods and Practices in Psychological Science*. 8, 4.

<https://doi.org/10.1177/25152459251377093>

Hothorn, T., Hornik, K., & Zeileis, A. (2006). Unbiased Recursive Partitioning: A Conditional Inference Framework. *Journal of Computational and Graphical Statistics*, 15(3), 651–674. <https://doi.org/10.1198/106186006X133933>

Hu, L. T., & Bentler, P. M. (1999). Cutoff criteria for fit indexes in covariance structure analysis: Conventional criteria versus new alternatives. *Structural Equation Modeling: A Multidisciplinary Journal*, 6(1), 1–55.

<https://doi.org/10.1080/10705519909540118>

Jorgensen, T. D., Pornprasertmanit, S., Schoemann, A. M., & Rosseel, Y. (2025). *semTools: Useful tools for structural equation modeling*. R package version 0.5-7. <https://CRAN.R-project.org/package=semTools>

Kambeitz, J., Schiffman, J., Kambeitz-Ilankovic, L., Mittal, V. A., Ettinger, U., & Vogeley, K. (2025). The empirical structure of psychopathology is represented in large language models. *Nature Mental Health*, 3, 1482–1492. <https://doi.org/10.1038/s44220-025-00527-y>

Kline, R. B. (2023). *Principles and Practice of Structural Equation Modeling* (5th ed.). Guilford Publications.

Kjell, O. N. E., Kjell, K., Garcia, D., & Sikström, S. (2019). Semantic measures: Using natural language processing to measure, differentiate, and describe psychological constructs. *Psychological methods*, 24(1), 92–115.

<https://doi.org/10.1037/met0000191>

Kjell, K., Kjell, O. N., & Schwartz, H. A. (2024). Beyond rating scales: With targeted evaluation, large language models are poised for psychological assessment. *Psychiatry Research*, 333,

115667. <https://doi.org/10.1016/j.psychres.2023.115667>

Kotov, R., Krueger, R. F., Watson, D., Achenbach, T. M., Althoff, R. R., Bagby, R. M., Brown, T. A., Carpenter, W. T., Caspi, A., Clark, L. A., Eaton, N. R., Forbes, M. K., Forbush, K. T., Goldberg, D., Hasin, D., Hyman, S. E., Ivanova, M. Y., Lynam, D. R., Markon, K., . . . Zimmerman, M. (2017). The Hierarchical Taxonomy of Psychopathology (HiTOP): A dimensional alternative to traditional nosologies. *Journal of Abnormal Psychology*, 126(4), 454–477.

<https://doi.org/10.1037/abn0000258>

Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. *Journal of Statistical Software*, 28(5), 1–26. <https://doi.org/10.18637/jss.v028.i05>

Lovibond, P. F., & Lovibond, S. H. (1995). The structure of negative emotional states: Comparison of the Depression Anxiety Stress Scales (DASS) with the Beck Depression and Anxiety Inventories. *Behaviour Research and Therapy*, 33(3), 335–343. [https://doi.org/10.1016/0005-7967\(94\)00075-U](https://doi.org/10.1016/0005-7967(94)00075-U)

Marsh, H. W., Hau, K. T., & Wen, Z. (2004). In search of golden rules: Comment on hypothesis-testing approaches to setting cutoff values for fit indexes and dangers in overgeneralizing Hu and Bentler's (1999) findings. *Structural Equation Modeling*:

A Multidisciplinary Journal, 11(3), 320–341.

https://doi.org/10.1207/s15328007sem1103_2

Nunes, L. Y. O., Lemos, D. C. L., Júnior, R. de C. R., Behar, C. B., & dos Santos, P. P. P. (2019). Análise psicométrica da PANAS no Brasil. *Ciencias Psicológicas*, 13(1), 45–55. <https://doi.org/10.22235/cp.v13i1.1808>

OpenAI. (2024, January 25). *New embedding models and API updates*. <https://openai.com/index/new-embedding-models-and-api-updates/>

Peixoto, E. M., Oliveira, K. S., Campos, C. R., Gagnon, J., Zanini, D. S., Nakano, T. C., & Bueno, J. M. H. (2021). DASS-21: assessment of psychological distress through the Bifactor Model and item analysis. *Psico-USF*, 26(4), 757–769. <http://dx.doi.org/10.1590/1413-82712021260413>

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982–3992. <https://doi.org/10.18653/v1/D19-1410>

Rosenbusch, H., Wanders, F., & Pit, I. L. (2020). The Semantic Scale Network: An online tool to detect semantic overlap of psychological scales and prevent scale redundancies. *Psychological methods*, 25(3), 380–392. <https://doi.org/10.1037/met0000244>

Rosseel, Y. (2012). lavaan: An R Package for Structural Equation Modeling. *Journal of Statistical Software*, 48(2), 1–36. <https://doi.org/10.18637/jss.v048.i02>

Rosseel, Y., Jorgensen, T. D., & De Wilde, L. (2025). *lavaan: Latent Variable Analysis*. R package version 0.6-20. <https://doi.org/10.32614/CRAN.package.lavaan>

Rudnytskyi, I. (2023). *openai: R Wrapper for OpenAI API*. R package version 0.4.1. <https://doi.org/10.32614/CRAN.package.openai>

- Song, K., Tan, X., Qin, T., Lu, J., & Liu, T.-Y. (2020). MPNet: Masked and Permuted Pre-training for Language Understanding. *Advances in Neural Information Processing Systems*, 33, 16857–16867.
- Steer, R. A., Ranieri, W. F., Beck, A. T., & Clark, D. A. (1993). Further evidence for the validity of the Beck Anxiety Inventory with psychiatric outpatients. *Journal of Anxiety Disorders*, 7(3), 195–205. [https://doi.org/10.1016/0887-6185\(93\)90002-3](https://doi.org/10.1016/0887-6185(93)90002-3)
- Suárez-Álvarez, J., He, Q., Guenole, N., & D’Urso, D. (2026). Using Artificial Intelligence in Test Construction: A Practical Guide. *Psicothema*, 38(1), 1-12. <https://doi.org/10.70478/psicothema.2026.38.01>
- Ushey, K., Allaire, J., & Tang, Y. (2025). *reticulate: Interface to 'Python'*. R package version 1.44.1. <https://CRAN.R-project.org/package=reticulate>
- Vignola, R. C. B., & Tucci, A. M. (2014). Adaptation and validation of the depression, anxiety and stress scale (DASS) to Brazilian Portuguese. *Journal of Affective Disorders*, 155, 104–109. <https://doi.org/10.1016/j.jad.2013.10.031>
- Wang, Y.-P., & Gorenstein, C.. (2013). Psychometric properties of the Beck Depression Inventory-II: a comprehensive review. *Brazilian Journal of Psychiatry*, 35(4), 416–431. <https://doi.org/10.1590/1516-4446-2012-1048>
- Watson, D., Clark, L. A., & Tellegen, A. (1988). Development and validation of brief measures of positive and negative affect: The PANAS scales. *Journal of Personality and Social Psychology*, 54(6), 1063–1070. <https://doi.org/10.1037/0022-3514.54.6.1063>
- Wulff, D. U. (2025). *embedR: Embed and analyze text*. R package version 0.1.0. <https://doi.org/10.32614/CRAN.package.embedR>